PolyShare - Cloud computing
Rapport d'architecture

Alexandre CLÉMENT - Alexandre HILTCHER - David LANG - Florian LEHMANN

Ce document présente l'architecture globale de l'application Polyshare. Celle-ci est développée dans le cadre du cours de Cloud Computing qui utilise les services de Google Cloud Platform. Il présente l'architecture globale du projet et rentre ensuite dans les détails sur l'utilisation des queues de messages et l'élasticité. Finalement il présente une estimation du prix de l'application.

Architecture globale

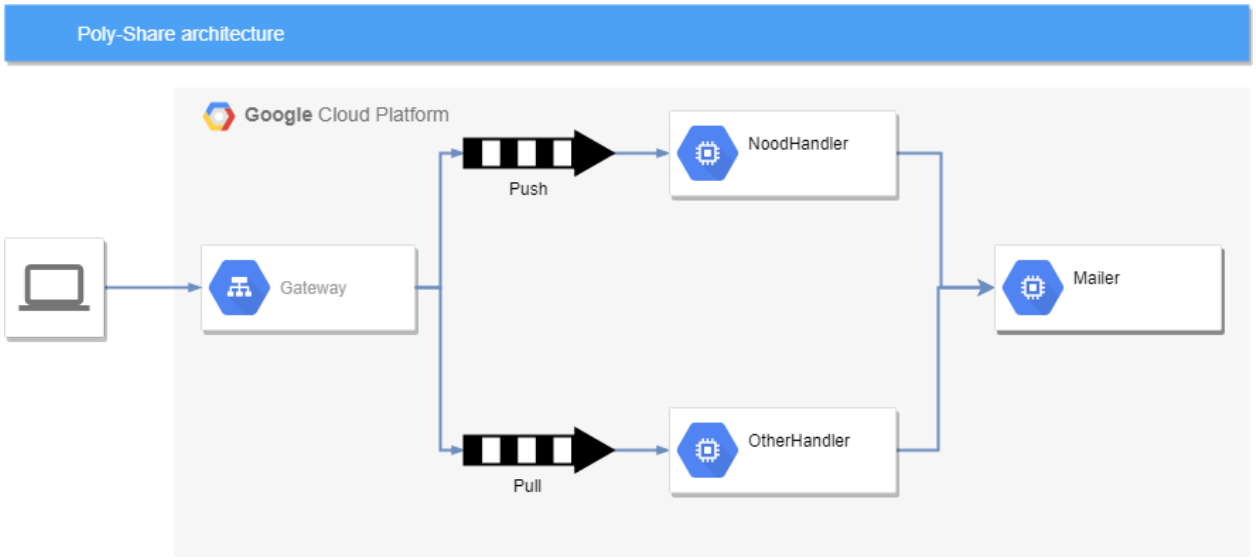

Le diagramme ci-dessus présente l'architecture globale de notre application. Cette application est découpée en 4 composants et 2 queues de messages:

Le premier composant est la *Gateway*, il permet de rediriger les requêtes vers les différentes queues de messages. Il va aussi s'occuper de tout ce qui ne dépend pas des autres composants comme la génération de page HTML, la gestion des comptes utilisateurs.

Le *NoobHandler* va s'occuper de traiter les informations d'upload et de download des utilisateurs "*noob*". Il va donc pour chaque requête d'un utilisateur vérifier si cet utilisateur n'a pas dépassé son quota et ensuite transmettre un message au *Mailer.*

Le *OtherHandler* va s'occuper de gérer les deux autres types des comptes, en effet, ces derniers ne se verront pas refuser une requête si leur quota est dépassé, ils seront plutôt mis en attente. C'est pourquoi nous avons choisi de les séparer. De plus, ces deux composants n'utiliseront pas le même type de queue. En effet, si le *OtherHandler* a besoin d'une pull queue afin de pouvoir remettre en queue certains messages, le *NoobHandler*, n'en pas besoin.

Finalement, le *Mailer* est le composant responsable d'envoyer les mails aux différents utilisateurs afin de leur fournir les liens nécessaires à l'upload ou au download de leurs fichiers.

Utilisation des queues

Gestion des noobs

Les téléchargements des noobs vont être gérés grâce à une push queue. Les messages seront traités comme ils arrivent (FIFO). Pour vérifier si le noob peut ou non avoir le lien de téléchargement, le handler de la *push queue* va envoyer une requête à la base de données qui conserve l'état de chaque personne. Si la limite de téléchargement de la personne est atteinte alors la requête sera refusée.

La gestion de l'upload, se fait de la manière suivante : un utilisateur émet une requête qui va être mise dans la push queue. Lorsque le message est traité par le handler, si l'utilisateur n'a pas dépassé son quota, le handler va écrire les métadonnées dans la base de donnée et générer un lien permettant l'upload du fichier. Ensuite ce lien sera envoyé à l'utilisateur par mail afin qu'il puisse upload son fichier. Si l'utilisateur a dépassé son quota il recevra alors un mail avec le message suivant "*lol non noob*".

Gestion des autres

Les autres utilisateurs vont être gérés avec une pull queue. Si un utilisateur dépasse son quotas de téléchargements alors le message traité par le *handler* est remis dans la queue. Le gros problème de cette implémentation est de trouver un algorithme efficace pour dupliquer les handlers. En effet, nous devons faire la distinction entre une queue de message saturée car il y a trop d'utilisateurs différents ou une queue de message saturée car il y a trop de requêtes de mêmes utilisateurs.

L'upload sera géré de la même façon que pour les noobs. La différence principale est que cela sera géré par le *OtherHandler* via une pull queue. Ceci nous permet de ne pas être forcé à refuser la requête de l'utilisateur mais simplement le mettre en attente.

Utilisation de l'élasticité

Nous n'avons qu'un service, notre élasticité se fait donc au niveau de celui-ci. Quand la charge sera trop importante de nouvelles instances de celui-ci seront créées. Nous pourrons gérer plusieurs opérations en simultané grâce à la *Queue*. Il faudra néanmoins gérer la création d'instances des handlers de la pull queue comme expliqué dans la partie précédente, ce problème ne sera pas facile à résoudre.

En théorie nous aurions pu tout gérer avec une seule Queue afin d'en limiter le nombre et ainsi limiter le prix au maximum (si nous n'avons pas trop de messages stockés). Cependant, cette solution pourrait limiter la disponibilité de nos services à nos utilisateurs "privilégiés" car une seule Queue regrouperait l'ensemble des requêtes. Contrairement à la solution précédente, notre solution permet de fournir un accès privilégié à certains utilisateurs au dépit du passage à l'échelle qui est réalisé sur l'intégralité du service. Ce passage à l'échelle à lieu malgré le fait que nous puissions avoir un nombre asymétrique de message entre les deux queues de messages. Ce passage à l'échelle nécessite donc plus de ressources matérielles.

Coût de la plateforme

Le tableau ci-dessous présente une estimation des opérations effectuées pour chaque type d'utilisateur.

Type d'utilisateur	Nombre maximum d'opérations par minute	Nombre moyen d'opérations par jour	Nombre moyen d'opérations par mois
Noob	1	10	300
Casual	2	20	600
Leet	4	40	1 200

Nous estimons que chaque type d'utilisateurs (les noobs, les casuals et les leets) représentent à chaque instant (33%) des utilisateurs de la plateforme. Nous pouvons en déduire une moyenne de requête pour un utilisateur. Cette moyenne est donc de 23.3 opérations par jours par utilisateur.

A partir d'ici, afin de réaliser les calculs de coût, nous allons nous baser sur un pool de 1000 utilisateurs. Pour ce pool, nous avons donc en moyenne 23 000 opérations par jours à gérer.

Les quotas gratuits offerts par chaque service ne nous permettent pas de supporter le nombre d'utilisateurs définis précédemment. En supposant que chaque instance d'AppEngine supporte 100 utilisateurs, nous avons besoin de 10 instances par heures. Cependant, si on considère que la moitié du trafic se fera lors d'un pic d'utilisation, on peut donc dire qu'à ce moment-là on aura besoin de 5 instances. De ce fait, nous pouvons aussi considérer que pour le reste du temps nous aurons besoin de moins d'instances (disons 1). De plus, nous considérons que le pic d'activité se déroule entre 18 et 21h (quand les étudiants rentrent de cours). Nous avons donc 5 instances pendant 3h par jour et 1 pendant 21h. Ceci nous donne une moyenne de 1.125 instances par heure. Sachant que 2 instances par heure nous coûteraient 71.5$ par mois, le coût de notre application sera majoré par 71.5$.

Le service de Mailing de base de google cloud nous limite à un quota de 10 mails par jour ce qui est largement insuffisant lors d'une utilisation quotidienne par un grand nombre d'utilisateurs. C'est pourquoi nous envisageons d'utiliser le service Mailgun[1] qui permet d'envoyer plus de 5 millions de mails par mois. Nous avons estimé qu'il y a environ 2 fois plus de download que d'upload. À partir de là, nous pouvons estimer qu'il faudra envoyer environ 460 000 mails par mois. Le coût pour notre pool de 1000 utilisateurs s'élève donc à environ 250$ par mois.

Finalement, en prenant en compte le coût des instances et le coût des mails le prix mensuel total s'élèverait à environ 321.5$. Nos utilisateurs nous reviennent donc à 0.315$ par mois.

[1] https://cloud.google.com/appengine/docs/standard/python/mail/mailgun